

# 배이시언 결정 이론



Pattern Recognition & Machine Learning Laboratory  
Ji-Hoon Park, July 06, 2021



# 확률과 통계(1/4)

## ■ 확률 기초

### ➤ 확률 분포 함수

- 예 : 이산 확률 분포, 연속 확률 분포

### ➤ 조건부 확률

- 선행된 조건 하에 발생하는 확률

- 예:  $P(B|A)$

### ➤ 결합 확률

- 두가지 서로 다른 사건이 동시에 일어날 확률

- 예:  $P(A, B)$

### ➤ 주변 확률

- 예:  $P(C) = P(C|A)P(A) + P(C|B)P(B)$

### ➤ 사전 확률

- 연이어 일어나는 사건에서 두 번째 사건이 발생하기 전에 작용하는 확률

### ➤ 우도 함수

- 한 사건이 관찰되어 고정되어 있고 사전 사건에 따라 확률을 계산

### ➤ 사후 확률

- 사건  $Y$ 가 일어난 후에 따지는 조건부 확률
- 사건  $Y$ 가 일어나 고정되고 이전에 발생한 사건  $X$ 에 따라 확률을 계산
  - 예:  $P(X|Y)$



# 확률과 통계(2/4)

## ➤ 베이스 정리

- 결합 확률과 곱규칙에 따라 식 도출

$$- P(X|Y) = \frac{P(Y|X)P(X)}{P(Y)} = \frac{\text{우도} \times \text{사전확률}}{P(Y)}$$

## ■ 평균과 분산

### ➤ 이산 확률 분포

- $\mu = \sum_x xP(x)$ 
  - $\mu$ : 평균
  - $P(x)$ : 이산 확률

- $\sigma^2 = \sum_x (x - \mu)^2 P(x)$

### ➤ 연속 확률 분포


- $\mu = \int_{-\infty}^{\infty} xp(x) dx$ 
  - $p(x)$ : 연속 확률

- $\sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 p(x) dx$


### ➤ 샘플 집합

- $\mu = \frac{1}{N} \sum_{i=1}^N x_i$ 
  - $N$ : 샘플 집합 갯수

- $\sigma^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \mu)^2$



이산 확률 분포



연속 확률 분포



# 확률과 통계(3/4)

## ➤ d차원 특징 벡터의 평균 벡터

### • 이산 확률 분포

$$\mu = \sum_{\mathbf{x}} \mathbf{x} P(\mathbf{x})$$

»  $\mathbf{x}$ :  $d$  차원 벡터

### • 연속 확률 분포

$$\mu = \int_{R^d} \mathbf{x} p(\mathbf{x}) d\mathbf{x}$$

»  $R^d$ :  $d$  차원 실수 공간

### • 샘플 집합

$$\mu = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i$$

## ➤ d차원 특징 벡터의 공분산

- 공분산은 랜덤 벡터를 구성하는 랜덤 변수간의 관계를 표현
- 양수인 경우 두 변수는 양의 관계, 음수인 경우 음의 관계

### • 이산 확률 분포

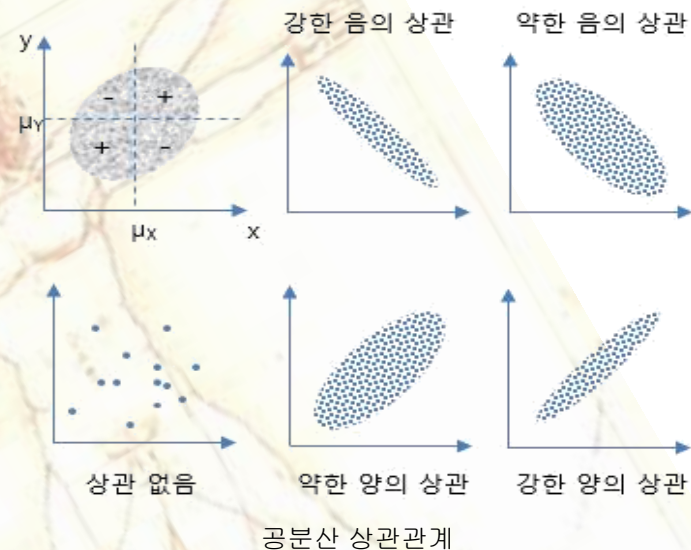
$$\Sigma = \sum_{\mathbf{x}} (\mathbf{x} - \mu) (\mathbf{x} - \mu)^T P(\mathbf{x})$$

### • 연속 확률 분포

$$\Sigma = \int_{R^d} (\mathbf{x} - \mu) (\mathbf{x} - \mu)^T p(\mathbf{x}) d\mathbf{x}$$

### • 샘플 집합

$$\Sigma = \frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^T$$







# 확률과 통계(4/4) & 베이지언 분류기(1/3)

## ■ 확률 분포의 표현과 추정

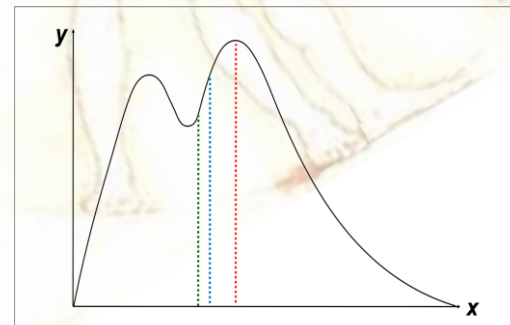

### ➤ $d$ 개의 변수 증가로 $d$ 차원의 배열 사용으로 차원의 저주 발생

- 확률 밀도함수를 정규 분포로 근사화
  - 평균  $\mu$ 와 분산  $\sigma^2$  설정하여 표현
- 여러 개의 모드를 가진 분포
  - 정규분포 표현 불가

## ■ 최소 오류 베이지언 분류기

### ➤ 분류 문제의 해결

- $x$ 를 발생시켰을 가능성이 가장 큰 부류 선택
  - $P(w_1|x)$ 와  $P(w_2|x)$  비교
    - »  $P(w_1|x) > P(w_2|x)$ 이면  $w_1$ 로 분류
    - »  $P(w_1|x) < P(w_2|x)$ 이면  $w_2$ 로 분류



두 개의 모드를 가진 분포



# 베이시언 분류기(2/3)

## – 베이스 정리 이용하여 비교

- »  $p(x|w_1)P(w_1) > p(x|w_2)P(w_2)$  이면  $w_1$ 로 분류
- »  $p(x|w_1)P(w_1) < p(x|w_2)P(w_2)$  이면  $w_2$ 로 분류

## • 오류 확률 예측

### – 임계값 기준으로 분류

- »  $x > t$  이면  $w_2$ 로 분류
- »  $x < t$  이면  $w_1$ 로 분류

### – 분류했을 경우 잘못 선택한 경우 오류 확률로 계산

- » 그래프의 파란색 부분

$$E = \frac{1}{2} \left( \int_{-\infty}^t p(x|w_2) dx + \int_t^{\infty} p(x|w_1) dx \right) \leftarrow \text{사전 확률을 } 1/2 \text{로 가정했을 경우 오류율}$$

### – 임계값의 최적 위치

- » 두 그래프 겹치는 부분이 최소의 오류
- » 옮길 경우 오류 증가

## ■ 최소 위험 베이시언 분류기

### ➤ 분류 문제의 해결


## • 손실 행렬 이용하여 D를 최소화

$$D = d_1 P(w_1) + d_2 P(w_2)$$


- »  $P(w_1), P(w_2)$ : 사전확률

$$d_1 = c_{11} \int_{R_1} p(x|w_1) dx + c_{12} \int_{R_2} p(x|w_1) dx$$

$$d_2 = c_{21} \int_{R_1} p(x|w_2) dx + c_{22} \int_{R_2} p(x|w_2) dx$$



베이시언 분류기의 오류 확률



베이시언 분류기 미사용 오류 확률



# 베이시언 분류기(3/3) & 분별 함수(1/2)

»  $P(w_1), P(w_2)$ : 사전확률

-  $x$ 를  $q_2 > q_1$ 이면  $w_1$ 으로 분류,  $q_2 < q_1$ 이면  $w_2$ 으로 분류

»  $q_1 = c_{11}p(x|w_1)P(w_1) + c_{21}p(x|w_2)P(w_2)$

»  $q_2 = c_{12}p(x|w_1)P(w_1) + c_{22}p(x|w_2)P(w_2)$

## • 우도비 결정 규칙

-  $x$ 를  $\frac{p(x|w_1)}{p(x|w_2)} > T$  이면  $w_1$ 로 분류,  $\frac{p(x|w_1)}{p(x|w_2)} < T$  이면  $w_2$ 로 분류

»  $T = \frac{(c_{21}-c_{22})P(w_2)}{(c_{12}-c_{11})P(w_1)}$

-  $x$ 를  $p(x|w_1) > p(x|w_2) \frac{c_{21}}{c_{12}}$  이면  $w_1$ 로 분류,  $p(x|w_1) < p(x|w_2) \frac{c_{21}}{c_{12}}$  이면  $w_2$ 로 분류

## ■ M 부류로 확장


### ➤ M 부류 최소 위험 베이시언 분류기

•  $x$ 를  $k = \arg \min_i q_i$  일 때  $w_k$ 로 분류

-  $q_i = \sum_{j=1}^M p(x|w_j)P(w_j)$

## ■ 분별함수

➤ 패턴의 특징벡터  $x$ 를 받아  $M$ 개의 함수 값  $g_i(x)$  구하여 그 중 최고 값의 부류로 분류







# 분별 함수(2/2) & 정규 분포에서 베이시언 분류기(1/3)

- $g_i(x) = \frac{p(x|w_i)P(w_i)}{\sum_{j=1}^M c_j p(x|w_j)P(w_j)}$
- $x$ 를  $g_{12}(x) > 0$  이면  $w_1$ 로 분류,  $g_{12}(x) < 0$  이면  $w_2$ 로 분류
  - $g_{12}(x) = g_1(x) - g_2(x)$

## ■ 정규 분포의 베이시언 분류기

### ➤ 정규 분포

- 우도가 정규 분포를 따르는 특수한 경우에 대해 분류기가 가지는 성질 분석하여 두 부류의 영역을 나누는 경계 모양 분석
  - 현실 세계에 맞는 경우가 적지 않게 존재
  - 평균과 분산의 매개 변수만으로 표현
  - 수학적 증명 용이

### ➤ 정규 분포와 분별 함수

#### • 1차원 정규분포

$$N(\mu, \sigma^2) = \frac{1}{(2\pi)^{1/2}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

#### • 2차원 정규분포

$$N(\mu, \Sigma) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\mu)^T \Sigma^{-1}(\mathbf{x}-\mu)\right)$$





# 정규 분포에서 베이시언 분류기(2/3)

- 우도

- $p(\mathbf{x}|\mathbf{w}_i) = N(\boldsymbol{\mu}_i, \Sigma_i) = \frac{1}{(2\pi)^{d/2}|\Sigma_i|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_i)^T \Sigma_i^{-1}(\mathbf{x}-\boldsymbol{\mu}_i)\right)$

- 분별 함수

- $g_i(\mathbf{x}) = \ln p(\mathbf{x}|\mathbf{w}_i)P(\mathbf{w}_i)$

- $g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x}^T \Sigma_i^{-1} \mathbf{x} - 2\boldsymbol{\mu}_i^T \Sigma_i^{-1} \mathbf{x} + \boldsymbol{\mu}_i^T \Sigma_i^{-1} \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(\mathbf{w}_i)$

- »  $g_i(\mathbf{x}) = g_2(\mathbf{x})$  만족 해야 결정 경계 상에  $\mathbf{x}$  존재

- »  $g_{ij}(\mathbf{x}) = g_i(\mathbf{x}) - g_2(\mathbf{x})$ : 결정 경계 함수

- 선형 분별

- 공분산 행렬이 같은 경우

- $g_i(\mathbf{x})$ 에서  $i$ 와 무관한 항 제거

- $g_i(\mathbf{x}) = \Sigma_i^{-1} \boldsymbol{\mu}_i^T \mathbf{x} + \left(\ln P(\mathbf{w}_i) - \frac{1}{2} \boldsymbol{\mu}_i^T \Sigma_i^{-1} \boldsymbol{\mu}_i\right)$

- $g_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + b_i$  꼴

- 선형 분류기


- $g_{ij}(\mathbf{x}) = \mathbf{w}^T (\mathbf{x} - \mathbf{x}_0)$

- $\mathbf{x}_0$  지나고,  $\Sigma^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$ 에 수직

- 공분산 행렬  $\Sigma = \sigma^2 \mathbf{I}$

- $\boldsymbol{\mu}_i - \boldsymbol{\mu}_j$ 에 수직

- 등고선이 원형



선형 분류기



# 정규 분포에서 베이시언 분류기(3/3) & 베이시언 분류의 특성(1/2)

## ■ 2차 분별

### ➢ 다양한 공분식 행렬

#### • 2차 분별 분석

$$-g_i(x) = -\frac{1}{2}x^T \Sigma_i^{-1}x + \mu_i^T \Sigma_i^{-1}x - \frac{1}{2}\mu_i^T \Sigma_i^{-1}\mu_i - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(w_i)$$

## ■ 최소 거리 분류기

### ➢ 마할라노비스 거리

$$\bullet \left( (x - \mu_i)^T \Sigma^{-1} (x - \mu_i) \right)^{1/2}$$

### ➢ 유클리디언 거리

$$\bullet \left( (x - \mu_i)^T (x - \mu_i) \right)^{1/2}$$

### ➢ 베이시언분류기 최소 거리 분류기 형태

$$\bullet k = \arg \min_i \left( (x - \mu_i)^T \Sigma^{-1} (x - \mu_i) \right)^{1/2}$$


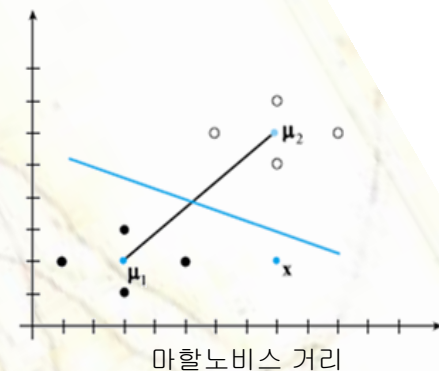
## ■ 베이시언 분류 특징

### ➢ 비현실성 내포

### ➢ 일반적인 확률 분포사용 시 차원의 저주 발생

### ➢ 오류율 측면에서 최적

### ➢ 확률을 신뢰도 값으로 삼아 후처리 등에 유용하게 활용 가능





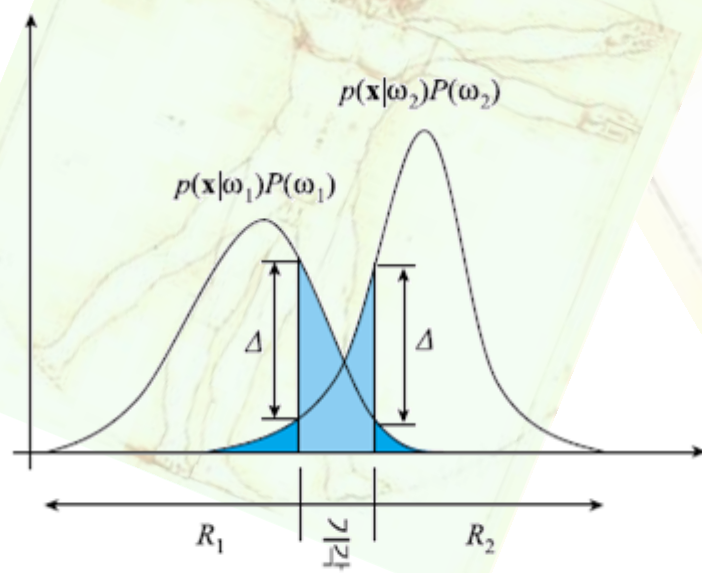
# 베이시언 분류의 특성(2/2) & 기각 처리

## ➤ 나이브 베이시언 분류기

- 차원의 저주 해결
- $p(\mathbf{x}|\mathbf{w}_i) = \prod_{j=1}^d p(x_j|\mathbf{w}_i)$

## ■ 기각 처리와 기각률


- 최소 오류 베이시언 분류기에서 두 부류의 확률 값 차이가  $\Delta$  이내 영역 기각
- 기각률: 기각으로 제외할 연한 파란색 영역
  - $p(\mathbf{x}|\mathbf{w}_i)P(\mathbf{w}_i)$ 를  $\sum_{j=1}^M c_{ji} p(x_j|\mathbf{w}_i)P(\mathbf{w}_j)$ 로 교체




기각 처리



x



x



x

차원의 저주