

# 신경망



**Pattern Recognition & Machine Learning Laboratory**

**Hyeon-Woo Bae**

**July. 07, 2021**



# 퍼셉트론(1/3)

## ■ 퍼셉트론의 구조

### ➤ 입력층과 출력층으로 구성

- 입력층 : 입력을 받아 출력층으로 전달하는 역할
  - $d + 1$ 개의 입력층 ( $d$  : 특징 벡터의 차원,  $1$  : 바이어스 노드 ( $x_0 = 1$ ))
- 출력층 : 출력을 내보내는 역할
  - $\omega_1$ 과  $\omega_2$ 로 분류하는 이진 분류기
  - 실제 구현에서는  $1$ 과  $-1$ ,  $1$ 과  $0$ 으로 표현
- 입력 노드와 출력 노드는 에지로 연결됨
  - $w$  : 가중치, 연결 강도

### ➤ 출력층에서의 합 계산 및 활성화함수(계단함수) 계산

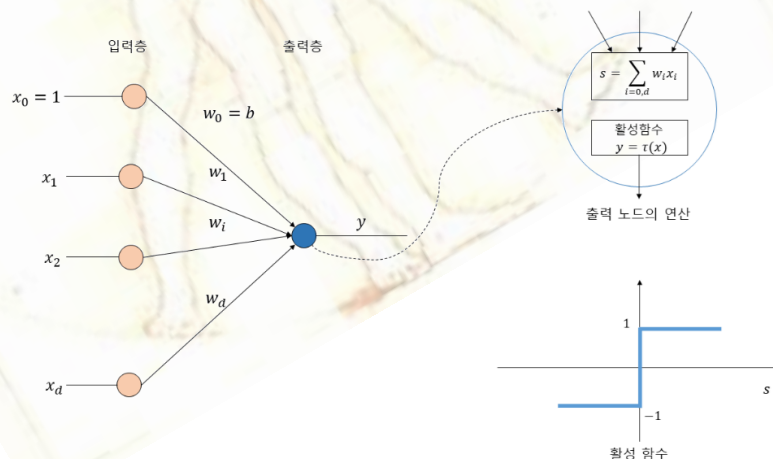
- $y = \tau(s) = \tau(\sum_{i=1}^d w_i x_i + b) = \tau(\mathbf{w}^T \mathbf{x} + b)$

- 이때  $\tau(s) = \begin{cases} +1, & s \geq 0 \\ -1, & s < 0 \end{cases}$

- 퍼셉트론은 활성화함수로 계단함수 사용

### ➤ 위 퍼셉트론은 선형 분류기에 해당됨

- $d(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b > 0$  이면  $\mathbf{x} \in \omega_1$
- $d(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b < 0$  이면  $\mathbf{x} \in \omega_2$
- $d(\cdot)$ 는 선형 분류기에서의 결정 직선



퍼셉트론의 구조



## 퍼셉트론(2/3)

### ■ 퍼셉트론 학습 알고리즘

#### ➤ 분류기 구조 정의 및 분류 과정을 수학적 식으로 표현

- $y = \tau(s) = \tau(\sum_{i=1}^d w_i x_i + b) = \tau(\mathbf{w}^T \mathbf{x} + b)$

- $\tau(s) = \begin{cases} +1, & s \geq 0 \\ -1, & s < 0 \end{cases}$

#### ➤ 분류기의 품질을 측정할 수 있는 비용 함수 $J(\Theta)$ 를 정의

- 퍼셉트론의 오류율을 비용 함수로 취함

- $J(\Theta) = \sum_{\mathbf{x}_k \in Y} (-t_k)(\mathbf{w}^T \mathbf{x}_k + b)$

- $Y$ 는 틀리게 분류되는 샘플의 집합

- $\mathbf{x}_k \in \omega_1$  일때,  $t_k = 1$ ,  $\mathbf{w}^T \mathbf{x}_k + b < 0$  (오분류) :  $J(\Theta) > 0$

- $\mathbf{x}_k \in \omega_2$  일때,  $t_k = -1$ ,  $\mathbf{w}^T \mathbf{x}_k + b > 0$  (오분류) :  $J(\Theta) > 0$

#### ➤ $J(\Theta)$ 를 최대 또는 최소로 하는 $\Theta$ 를 찾기 위한 알고리즘을 설계

- 최적화 알고리즘으로 내리막 경사법을 채택

- $J(\Theta) = 0$ 이 될 때까지 작은 값을 갖는 학습률  $\rho(h)$ 을 곱하여 조금씩 이동시키며 해를 구함

- $\Theta(h+1) = \Theta(h) - \rho(h) \frac{\partial J(\Theta)}{\partial \Theta}$

- $\frac{\partial J(\Theta)}{\partial \mathbf{w}} = \sum_{\mathbf{x}_k \in Y} (t_k \mathbf{x}_k)$

- $\frac{\partial J(\Theta)}{\partial b} = \sum_{\mathbf{x}_k \in Y} (-t_k)$





# 퍼셉트론(3/3)

## ■ 퍼셉트론 학습 알고리즘

- 퍼셉트론 학습 규칙(델타 규칙)

- $w(h+1) = w(h) + \rho(h) \sum_{x_k \in Y} t_k x_k$

- $b(h+1) = b(h) + \rho(h) \sum_{x_k \in Y} t_k$

- 퍼셉트론 학습 알고리즘은 반드시 수렴한다는 바람직한 특성을 가짐

- 훈련 집합이 선형 분리 가능한 경우에는 초기값으로 무엇을 가지고 출발하던지 반드시 훈련 집합 전체를 옳게 분류하는 퍼셉트론으로 수렴한다는 것이 증명되어 있음

- 퍼셉트론의 한계

- 선형 분리 불가능한 경우 틀리게 분류하는 경우가 반드시 생김
  - **OR, AND** 게이트와 달리 **XOR** 게이트의 동작에서는 샘플이 오분류될 수 밖에 없음



OR AND XOR 게이트




# 다층 퍼셉트론(1/4)

## ■ XOR 게이트

### ➤ XOR 게이트

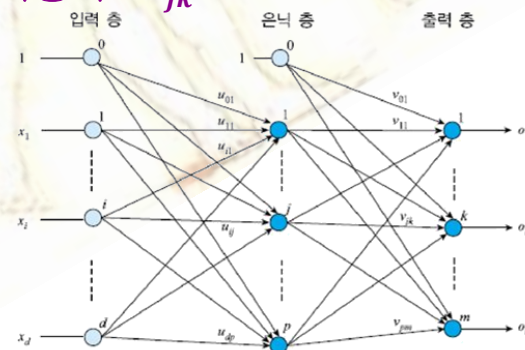
- $d_1(x)$ 와  $d_2(x)$ 를 각각 퍼셉트론으로 간주
  - $w_1^T x + b_1 > 0$  이고  $w_2^T x + b_2 > 0$  이면,  $x \in \omega_1$
  - $w_1^T x + b_1 < 0$  이거나  $w_2^T x + b_2 < 0$  이면,  $x \in \omega_2$
- 새로운 공간에서  $\omega_1$ 과  $\omega_2$ 를 최종 분류하는 퍼셉트론  $d_3(x)$



## ■ 다층 퍼셉트론의 구조

### ➤ 입력 층, 은닉 층, 출력 층

- 입력 층: 받은 값을 은닉 층으로 전달
- 은닉 층, 출력 층: 가중치 합과 활성화 함수 계산
- $i$ 번째 입력 노드에서  $j$ 번째 은닉 노드로 가는 에지의 가중치:  $u_{ij}$
- $j$ 번째 은닉 노드에서  $k$ 번째 출력 노드로 가는 에지의 가중치:  $v_{jk}$ 
  - 은닉 층의  $j$ 번째 노드,  $1 \leq j \leq p$
  - $z\_sum_j = \sum_{i=1}^d x_i u_{ij} + u_{0j}$
  - $z_j = \tau(z\_sum_j)$
  - 출력 층의  $k$ 번째 노드,  $1 \leq k \leq m$
  - $o\_sum_k = \sum_{j=1}^p z_j v_{jk} + v_{0k}$
  - $o_k = \tau(o\_sum_k)$



다층 퍼셉트론의 구조



# 다층 퍼셉트론(2/4)

## ■ 다층 퍼셉트론의 활성화 함수

### ➤ 시그모이드 함수

- 이진 시그모이드 함수

- 0~1 사이의 값을 가짐

- $\tau_1(x) = \frac{1}{1+e^{-\alpha x}}$

- $\tau_1'(x) = \alpha \tau_1(x)(1 - \tau_1(x))$

- 양극 시그모이드 함수

- -1~1사이의 값을 가짐

- $\tau_2(x) = \frac{2}{1+e^{-\alpha x}} - 1$

- $\tau_2'(x) = \frac{\alpha}{2}(1 + \tau_2(x))(1 - \tau_2(x))$

- $\alpha$ 가 클수록 경사가 급함

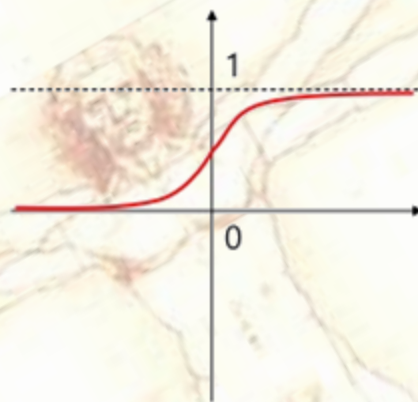
- $\alpha = \infty$  : 계단함수와 같은 결과

### ➤ 시그모이드 함수의 장점


- 전 구간에서 미분가능함

- 계산이 간단함

- 미분한 값이 자신을 포함하기 때문에 미분값 역시 계산이 간단함



이진 시그모이드



양극 시그모이드





# 다층 퍼셉트론(3/4)

## 다층 퍼셉트론 학습 이론

### 비율 함수 $J(\Theta)$ 를 정의

- 훈련 샘플  $\mathbf{x} = (x_1, x_2, \dots, x_d)^T$  입력 시 원하는 출력  $\mathbf{t} = (t_1, t_2, \dots, t_m)^T$
- 실제 출력  $\mathbf{o} = (o_1, o_2, \dots, o_m)^T$
- 오류  $E = \frac{1}{2} \sum_{k=1}^m (t_k - o_k)^2$ 를 줄이는 쪽으로 매개 변수  $\mathbf{u}$ 와  $\mathbf{v}$ 를 수정해 나가야 함
- $\mathbf{v}(h+1) = \mathbf{v}(h) + \Delta \mathbf{v} = \mathbf{v}(h) - \rho \frac{\partial E}{\partial \mathbf{v}}$
- $\mathbf{u}(h+1) = \mathbf{u}(h) + \Delta \mathbf{u} = \mathbf{u}(h) - \rho \frac{\partial E}{\partial \mathbf{u}}$

### $j$ 번째 은닉 노드와 $k$ 번째 출력 노드 간의 가중치 갱신값 $\Delta v_{jk}$ 유도

- $\frac{\partial E}{\partial v_{jk}} = -(t_k - o_k) \tau'(o\_sum_k) z_j$
- $\delta_k = (t_k - o_k) \tau'(o\_sum_k) z_j, 1 \leq k \leq m$
- $\Delta v_{jk} = -\rho \frac{\partial E}{\partial v_{jk}} = \rho \delta_k z_j, 0 \leq j \leq p, 1 \leq k \leq m$

### $i$ 번째 입력 노드와 $j$ 번째 은닉 노드 간의 가중치 갱신값 $\Delta u_{ij}$ 유도

- $\frac{\partial E}{\partial u_{ij}} = -\sum_{k=1}^m \delta_k v_{jk} \tau'(z\_sum_j) x_i$
- $\eta_j = \tau'(z\_sum_j) \sum_{k=1}^m \delta_k v_{jk}, 1 \leq j \leq p$
- $\Delta u_{ij} = -\rho \frac{\partial E}{\partial u_{ij}} = \rho \eta_j x_i, 0 \leq i \leq d, 1 \leq j \leq p$



# 다층 퍼셉트론(4/4)

## ■ 다층 퍼셉트론 학습 이론

### ➤ 알고리즘이 오류 $E$ 를 줄여나가는 원리

- 주어진 샘플에 대해 전방 계산으로 오류를 추정
- 출력 층에서 시작하여 반대 방향으로 전진하며 오류 전파(가중치 갱신)
- 이를 오류 역전파 알고리즘이라 함

### ➤ 중요한 고려 사항

- 은닉 노드의 수
  - 은닉 노드의 수가 많으면 변수에 비해 주어진 정보가 부족함
  - 은닉 노드의 수가 적으면 신경망의 용량이 작아 필요한 정보를 충분히 담을 수 없게 됨
- 초기값 설정
  - 초기값이 수렴 속도에 영향을 미치므로 보편적으로 작은 난수로 설정함
- 종료 시점 설정
  - 평균 제곱 오차가 어떤 임계값보다 작으면 멈춤
- 지역 최적 점 탈출
  - 내리막 경사법을 이용하기 때문에 초기값에 따라 지역 최적 점에 빠질 위험이 있음
  - 다중 시작 방법 : 여러 초기값으로 훈련하여 그중 가장 좋은 성능을 보이는 것을 선택
- 적절히 선택해야할 매개 변수가 많아 실험을 통해 설정할 필요가 있음